Cvičenie: Funkcie viacerých premenných

Optimalizácia a optimálne riadenie

Problém:

Podmienky optimálnosti

- Budeme uvažovať skalárnu funkciu n premenných
$$J(x): \mathbb{R}^n \to \mathbb{R}$$
kde $x \in \mathbb{R}^n$ je vektor premenných
- Pohybujeme sa v n-rozmernom priestore reálnych čísel $\mathbb{R}^n$
$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{pmatrix}$$
- Gradient – vektor prvých parciálnych derivácii podľa jednotlivých premenných
$$\nabla J(x) = \begin{pmatrix} \frac{\partial J(x)}{\partial x_1} \\ \frac{\partial J(x)}{\partial x_2} \\ \vdots \\ \frac{\partial J(x)}{\partial x_n} \end{pmatrix}$$
- Hessián je matica druhých parciálnych derivácii
$$\nabla^2 J(x) = \begin{pmatrix} \frac{\partial^2 J(x)}{\partial {x_1}^2} & \frac{\partial^2 J(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 J(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 J(x)}{\partial x_1 \partial x_2} & \frac{\partial^2 J(x)}{\partial {x_2}^2} & \cdots & \frac{\partial^2 J(x)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 J(x)}{\partial x_1 \partial x_n} & \frac{\partial^2 J(x)}{\partial x_2 \partial x_n} & \cdots & \frac{\partial^2 J(x)}{\partial {x_n}^2} \end{pmatrix}$$
- Stacionárny bod účelovej funkcie - gradient rovný nulovému vektoru (nevyhnutná podmienka pre extrém)
$$\nabla J(x^*) = \mathbf{0}$$
- Typy stacionárnych bodov na základe vlastností Hessiánu v bode x^* (**postačujúce podmienky pre extrém**)
  - Ak gradient $\nabla J(x^*) = \mathbf{0}$ a Hessián $\nabla^2 J(x^*) \succ 0$ (**kladne definitný**), funkcia má v bode x^* **minimum**
  - Ak gradient $\nabla J(x^*) = \mathbf{0}$ a Hessián $\nabla^2 J(x^*) \prec 0$ (**záporne definitný**), funkcia má v bode x^* **maximum**
  - Ak neplatí ani jedno, $\nabla^2 J(x^*)$ (**indefinitný**), funkcia má v bode x^* **sedlo**

Kvadratická forma

- Kvadratická forma - zovšeobecnenie kvadratickej funkcie pre viac premenných

$$J(x) = \frac{1}{2}x^T Ax + b^T x + c$$

$J(x) \in \mathbb{R}$ (skalár), $A \in \mathbb{R}^{n\times n}$ (matica), $b \in \mathbb{R}^n$ (vektor), $c \in \mathbb{R}$ (skalár)

- Gradient $\nabla J(x)$ kvadratickej formy je

$$\nabla J(x) = \nabla\left(\frac{1}{2}x^T Ax + b^T x + c\right) = Ax + b$$

- Hessián $\nabla^2 J(x)$ kvadratickej formy je

$$\nabla^2 J(x) = \nabla(Ax + b) = A$$

- Podmienka optimálnosti (stacionárny bod – nulový gradient)

$$\nabla J(x^*) = Ax^* + b = \mathbf{0}$$

- Stacionárny bod x^* spĺňa sústavu lineárnych rovníc

$$Ax^* = -b$$
$$x^* = -A^{-1}b$$

- Ak $Ax^* = -b$ a $A \succ 0$ (**kladne definitná**)
  - kvadratická forma je konvexná funkcia
  - v bode x^* je globálne **minimum**
- Ak $Ax^* = -b$ a $A \prec 0$ (**záporne definitná**)
  - kvadratická forma je konkávna funkcia
  - v bode x^* je globálne **maximum**
- Ak neplatí ani jedno, A je (**indefinitná**)
  - kvadratická forma má v bode x^* **sedlo**

Rozklad na vlastné čísla

- Majme symetrickú maticu $A \in \mathbb{R}^{n\times n}$, $A = A^T$
- Túto maticu možno rozložiť (diagonalizovať) (príkaz *eig*) ako

$$A = Q\Lambda Q^T = Q\Lambda Q^{-1}$$

$Q \in \mathbb{R}^{n\times n}$ je matica vlastných vektorov, ktorá spĺňa $Q^T = Q^{-1}$ a teda $Q^T Q = I$ (je ortogonálna)

$\Lambda \in \mathbb{R}^{n\times n}$ je diagonálna matica vlastných čísel

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}$$

- Definitnosť matice súvisí s jej vlastnými číslami
  - Ak sú všetky vlastné čísla kladné tak matica je kladne definitná
  - Ak sú všetky vlastné čísla záporné tak matica je záporne definitná
  - Ak sú vlastné čísla kladné aj záporné tak matica je indefinitná

Úloha:

Použite skript *functions_scr*

Analyzujte vlastnosti nasledovných kvadratických foriem

a)

$$A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 3 \end{pmatrix}, b = \begin{pmatrix} -6 \\ 10 \end{pmatrix}, c = 10$$

b)

$$A = -\begin{pmatrix} 1.5 & 0.2 \\ 0.2 & 2 \end{pmatrix}, b = \begin{pmatrix} -6 \\ 10 \end{pmatrix}, c = 10$$

c)

$$A = \begin{pmatrix} -2 & 0.5 \\ 0.5 & 3 \end{pmatrix}, b = \begin{pmatrix} -6 \\ 10 \end{pmatrix}, c = 10$$

Implementujte výpočet hodnoty kvadratickej formy, jej gradientu a Hessiánu (priečinok *fcn*)

```
function [J,g,H] = fcn_QF(x,A,b,c)

J=%TOOD
g=%TOOD
H=%TOOD

end
```

- Určite stacionárny bod kvadratickej formy

```
x_opt=%TODO
```

- Určite rozklad matice A na vlastné čísla, vyhodnoťte jej definitnosť a charakter extrému

```
[Q,Lambda]=%TODO
```

- Overte rozklad a ortogonalitu

$$A = Q\Lambda Q^T$$
$$QQ^T = I$$

Vyhodnoťte účelovú funkciu v stacionárnom bode

```
J_opt=%TODO
```

Vyhodnoťte účelovú funkciu a jej gradient naprieč priestorovou mriežkou premenných

```
x=[x1(i,j);x2(i,j)];
[J(i,j),g]=%TODO
```

Analyzujte vlastnosti Himmelblau funkcie (polynóm štvrtého stupňa, viacero extrémov)

$$J(x) = ({x_1}^2 + x_2 - 11)^2 + (x_1 + {x_2}^2 - 7)^2$$

Nájdite prvé derivácie a gradient

$$\frac{\partial J(x)}{\partial x_1}, \frac{\partial J(x)}{\partial x_2}$$

Nájdite druhé derivácie a Hessián:

$$\frac{\partial^2 J(x)}{\partial {x_1}^2}, \frac{\partial^2 J(x)}{\partial {x_2}^2}, \frac{\partial^2 J(x)}{\partial x_1 \partial x_2}$$

Implementujte výpočet hodnoty Himmelblau funkcie, jej gradientu a Hessiánu (priečinok *fcn*)

```
function [J,g,H] = fcn_himmelblau(x)
J=%TODO;
g=[%TODO];
H=[%TODO];
end
```

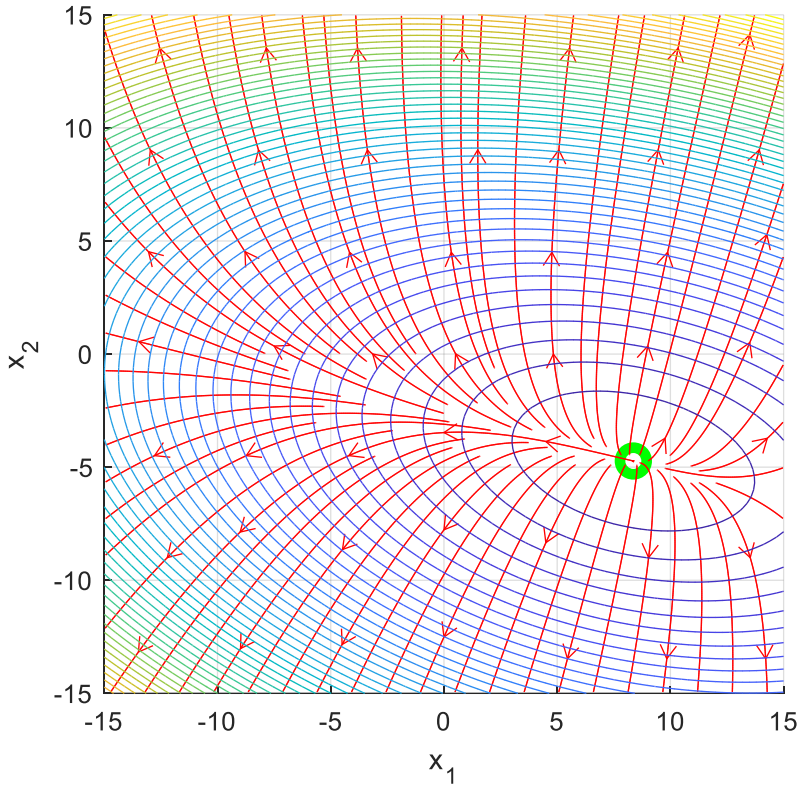
Vyhodnoťte účelovú funkciu a jej gradient naprieč priestorovou mriežkou premenných

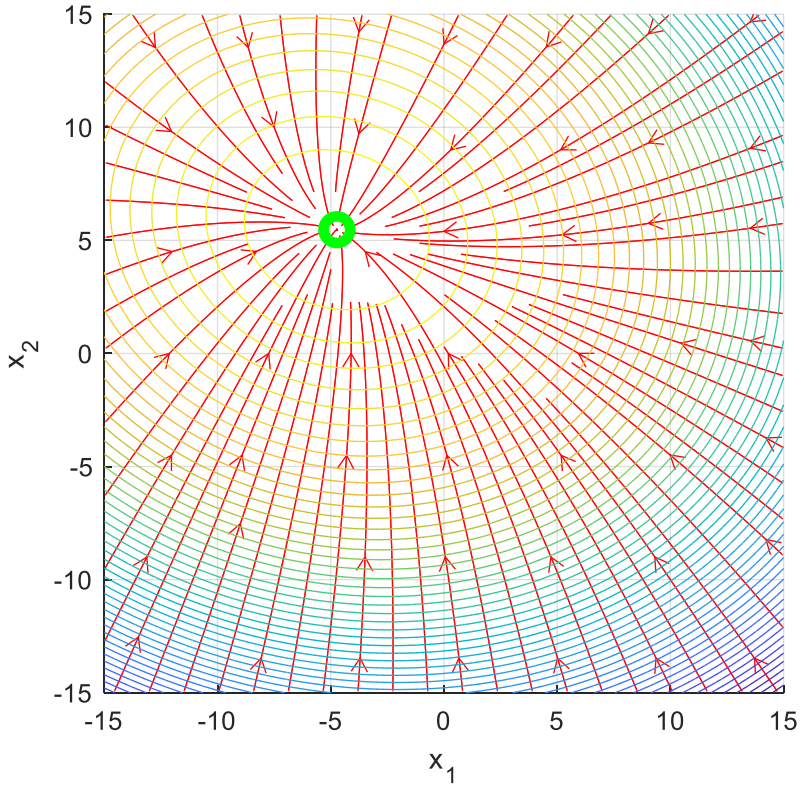
```
x=[x1(i,j);x2(i,j)];
[J(i,j),g]=%TODO
```

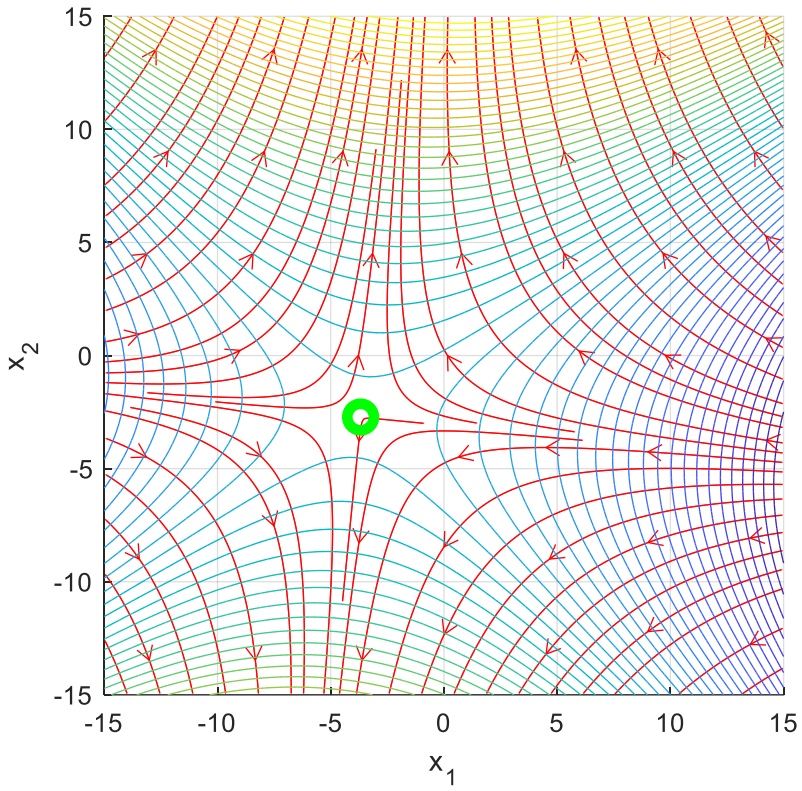
Vyhodnoťte definitnosť Hessiánu vo vybraných bodoch a určite charakter funkcie v okolí tohto bodu

```
x0=[3.584458;-1.848126];
x0=[-3.0730   -0.0814];
x0=[-0.2708   -0.9230];
```

Riešenie:


15
10
5
0
-5
-10
-15
x2
-15
-10
-5
0
5
10
15
x1


15
10
5
0
-5
-10
-15
x2
-15
-10
-5
0
5
10
15
x1



Himmelblau funkcia a jej derivácie:

$$J(x) = ({x_1}^2 + x_2 - 11)^2 + (x_1 + {x_2}^2 - 7)^2$$

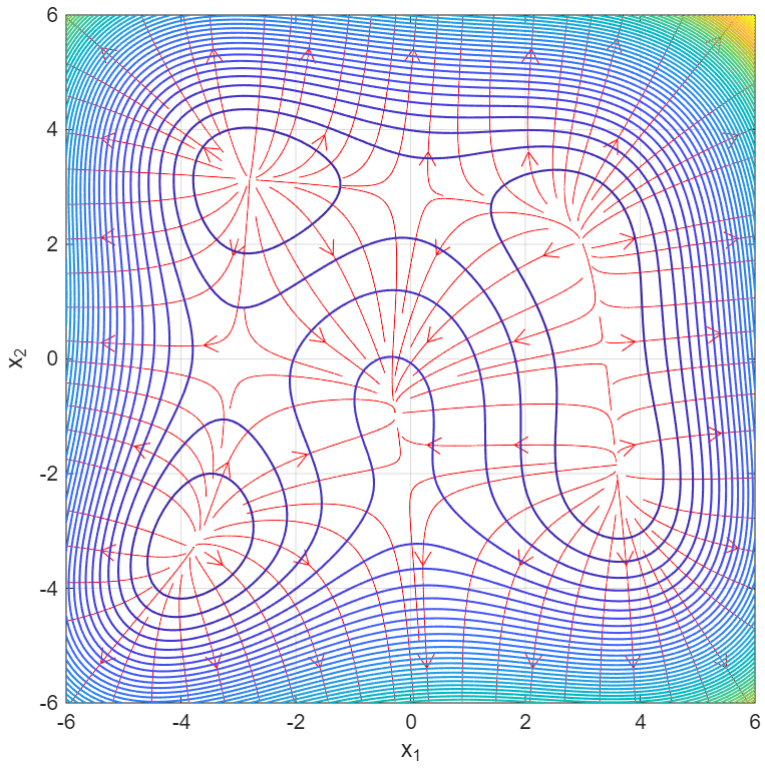
$$\frac{\partial J(x)}{\partial x_1} = 4x_1({x_1}^2 + x_2 - 11) + 2(x_1 + {x_2}^2 - 7)$$

$$\frac{\partial J(x)}{\partial x_2} = 2({x_1}^2 + x_2 - 11) + 4x_2(x_1 + {x_2}^2 - 7)$$

$$\frac{\partial^2 J(x)}{\partial {x_1}^2} = 12{x_1}^2 + 4x_2 - 42$$

$$\frac{\partial^2 J(x)}{\partial {x_2}^2} = 2 + 4(x_1 + {x_2}^2 - 7) + 8{x_2}^2 = 12{x_2}^2 + 4x_1 - 26$$

$$\frac{\partial^2 J(x)}{\partial x_1 \partial x_2} = 4x_1 + 4x_2$$


6
4
2
0
-2
-4
-6
x2
-6
-4
-2
0
2
4
6
x1